

# Текст

## Лекција 7

Стеван Гостојић

Факултет техничких наука, Нови Сад

4. мај 2023.

# Преглед садржаја

- 1 Увод
- 2 Текст
- 3 Претрага и индексирање
- 4 Apache Lucene Core
- 5 Закључак

# Преглед садржаја

- 1 Увод
- 2 Текст
- 3 Претрага и индексирање
- 4 Apache Lucene Core
- 5 Закључак

# Текст

- Текст је, у општем случају, низ знакова који преносе неку поруку

# Текст

- Велика количина информација складишти се и преноси у облику текста (тј. текстуалних докумената као јединичних носилаца информација)
- Технике и алати за складиштење и претраживање текста разликују се од техника и алата за складиштење других врста информација
- Познавање ових техника и алата доприноси писању ефикаснијих и ефектнијих рачунарских програма који обрађују текст

# Преглед садржаја

- 1 Увод
- 2 Текст
- 3 Претрага и индексирање
- 4 Apache Lucene Core
- 5 Закључак

# Репрезентација текста

- Посоји више метода за рачунарску репрезентацију текста
- Неке од тих метода су представљање текста као низа знакова, као вектора и као фреквенције  $n$ -торки

# Низ знакова

- Текст можемо да представимо као низ знакова (који су кодирани одређеним кодом)
- Временом су настали различити кодови за кодирање знакова



# Вектор

- Други начин за репрезентацију текста је вектор речи (тј. токена)
- У том случају су димензије вектора речи које се појављују у тексту, а интензитет појединачних компоненти вектора број појављивања одговарајуће речи у документу

# Фреквенција н-торки

- Текст можемо да представимо и као фреквенцију појављивања различитих н-торки речи у тексту
- Можемо да посматрамо уређене парове, уређене тројке, уређене четворке итд.

# Кодирање знакова

- С обзиром да рачунари податке складиште, преносе и обрађују као низ бита, знаке неког језика је потребно кодирати у неком коду
- Код је пресликавање скупа знакова на скуп бинарних речи
- Постоје многи стандарди за кодирање знакова од којих је данас у најширој употреби Unicode

# ASCII

- American Standard Code for Information Interchange (ASCII)  
је је стандард за кодирање текста
- Садржи 128 знакова (од којих су неки контролни знаци)
- Основа је модерних стандарда за кодирање текста

## ASCII

Знак	Код (децимално)	Код (бинарно)
A	65	100 0001
B	66	100 0010
C	67	100 0011
a	97	110 0001
b	98	110 0010
c	99	110 0011

Table 1: ASCII

# ISO/IEC 8859

- ISO/IEC 8859 је фамилија стандарда за кодирање знакова која је заједнички прописана од ISO и IEC
- То је проширење ASCII стандарда
- ISO/IEC 8859 је подељен у неколико делова који стандардизују кодирање знакова различитих језика (нпр. ISO/IEC 8859-2 садржи српске латиничке знакове, а ISO/IEC 8859-5 српске ћириличне знакове)

# Unicode

- Unicode је стандард за конзистентно кодирање, репрезентацију и руковање текстом
- Такође је проширење ASCII стандарда
- Садржи више 144,697 знакова који покривају 159 језика (верзија 14.0 од септембра 2021 )
- Знакови се могу кодирати на више начина (UTF-8, UTF-16, UTF-32 итд.)
- Прописује га Јуникод конзорцијум (енг. Unicode Consortium)

# Преглед садржаја

- 1 Увод
- 2 Текст
- 3 Претрага и индексирање**
- 4 Apache Lucene Core
- 5 Закључак



# Проналажење

- Проналажење (енг. retrieval) или претрага (енг. search) текста је процес одабира докумената који задовољавају одређени упит
- На пример, претраживање интернета коришћењем Google претраживача

# Прегледање

- Прегледање (енг. browsing) текста је процес одабира докумената на основу веза са другим документима
- На пример, праћење хиперлика од једног HTML документа до другог HTML документа

# Индексирање текста

- Индексирање текста је процес прављења индекса у циљу убрзавања претраге текста
- Појам индекса потиче из библиотечке делатности
- У зависности од техника које се користе за (рачунарску) претрагу текста, индекси се имплементирају као различите структуре података

# Претраживачи

- Претраживачи (енг. search engine) су рачунарски програми чија је основна функција индексирање и претрага текстуалних докумената
- Претраживачи могу да буду понуђени као сервиси или као библиотеке које се уграђују у рачунарске програме

# Преглед садржаја

- 1 Увод
- 2 Текст
- 3 Претрага и индексирање
- 4 Apache Lucene Core**
- 5 Закључак


# Apache Lucene Core

- Apache Lucene Core је Java API за (индексирање) и претрагу текста
- Постоје конектори и за друге програмске језике и платформе (нпр. Python)
- Apache Lucene Core имплементира напредне методе претраге текста, има високе перформансе и захтева релативно мало ресурса

# Apache Lucene Core

- Основна јединица индексирања и претраге су (текстуални) документи
- Документи се састоје од поља (различити типови докумената састоје се од различитих поља)
- Сирови текстуални документи се преводе у једно или више поља (која могу а не морају да се индексирају и анализирају)

# Apache Lucene Core





# Lucene анализатори

- WhitespaceAnalyzer (дели текст на токене по белим знацима)
- SimpleAnalyzer (дели текст на токене по знацима који нису слова, па их претвара у мала слова)
- StopAnalyzer (исто као и SimpleAnalyzer, али и уклања тзв. "стоп речи")
- StandardAnalyzer (најчешће коришћен анализатор који, за разлику од StopAnalyzer анализатора, нуди и неке "напредне" функције као што је препознавање URL адреса, адреса електронске поште итд.)
- итд.

# WhitespaceAnalyzer

```
1 ' 'The quick brown fox jumped over the lazy dog' '  
2 [The] [quick] [brown] [fox] [jumped] [over] [the] [lazy] [dog]  
3
```

# WhitespaceAnalyzer

```
1 ' 'XY&Z Corporation - xyz@example.com ' '  
2 [XY&Z] [Corporation] [-] [xyz@example.com] ' '  
3
```

# SimpleAnalyzer

```
1 ' 'The quick brown fox jumped over the lazy dog' '  
2 [the] [quick] [brown] [fox] [jumped] [over] [the] [lazy] [dog]  
3
```

# SimpleAnalyzer

```
1 ' 'XY&Z Corporation — xyz@example.com' '  
2 [xy] [z] [corporation] [xyz] [example] [com]  
3
```

# StopAnalyzer

```
1 ' 'The quick brown fox jumped over the lazy dog' '  
2 [quick] [brown] [fox] [jumped] [over] [lazy] [dog]  
3
```

# StopAnalyzer

```
1 ' 'XY&Z Corporation — xyz@example.com ' '  
2 [xy] [z] [corporation] [xyz] [example] [com]  
3
```

# StandardAnalyzer

```
1 ' 'The quick brown fox jumped over the lazy dog' '  
2 [quick] [brown] [fox] [jumped] [over] [lazy] [dog]  
3
```



# StandardAnalyzer

```
1 ' 'XY&Z Corporation — xyz@example.com ' '  
2 [xy&z] [corporation] [xyz@example.com]  
3
```

# Apache Lucene Core

- Колекције текстуалних докумената могу да се претражују на два начина
- Први је Apache Lucene Core API
- Други је Apache Lucene Core Query Parser упитног језика

# Query Parser упитни језик

- Синтакса (и семантика) Query Parser упитног језика није стандардизована и може да (незнатно) варира од верзије до верзије Lucene-а
- У примерима је приказан упитни језик за Apache Lucene Core 9.1

# Термини

- Термини су појединачни термини или фразе
- Појединачни термини су речи
- Фразе су низ речи под двоструким наводницима

# Термини

```
1 Hello
2 "Hello World"
3
```

# Поља

- Поља су уређени парови кључ:вредност
- Вредности поља су термини
- Једно поље може да буде подразумевано (тада термини не морају да се квалификују кључем)

# Поља

```
1 title:"Hello World"  
2 title:Hello World  
3 text:go  
4 go  
5
```

# Упити

- Упити се састоје од поља и логичких оператора
- Логички оператори се користе да би се више поља комбиновало у (сложени) упит



# Lucene упити

```
1 title:"Hello World" AND text:go
2 title:"Hello World" AND go
3 title:Hello World
4
```

# Модификатори

- Модификатори су речи који се користе за модификовање термина (и упита)

# Модификатори

- Претраге "џокер" знацима (енг. wildcard searches)
- Претраге регуларним изразима (енг. regular expression searches)
- "Фази" претраге (енг. fuzzy searches)
- Претраге по близини (енг. proximity searches)
- Претраге по интервалима (енг. range searches)
- "Појачавање" термина (енг. boosting a term)
- Логички оператори (енг. boolean operators)
- Груписање (енг. grouping)

# Претраге "џокер" знацима

- Lucene подржава претрагу "џокер" знацима "?" и "\*" над појединачним терминима
- "џокер" знак "?" замењује било који знак
- "џокер" знак "\*" замењује било који низ знакова
- "џокер" знаци "?" и "\*" не могу да се налазе на почетку термина

# Претраге "џокер" знацима

```
1 te?t
2 test*
3
```

# Претраге регуларним изразима

- Lucene подржава претрагу регуларним изразима
- И синтакса (и семантика) регуларних израза може да (незнатно) варира од верзије до верзије Lucene-а
- Регуларни изрази наводе се између знакова "/"

# Претраге регуларним изразима

1 `/[mb] oat /`

2

# Регуларни изрази

- Регуларни изрази су низ знакова који специфицирају текстуални образац



# Регуларни изрази

Израз	Опис
<code>\d</code>	цифра
<code>\D</code>	све осим цифре
<code>\s</code>	бели знак
<code>\S</code>	све осим белог знака
<code>\w</code>	слово
<code>\W</code>	све осим слова

Table 2: Регуларни изрази

# Регуларни изрази

Израз	Опис
.	било који знак
"текст"	текст
[abcde]	класа знакова
[^abcde]	негација класе знакова
	унија

Table 3: Регуларни изрази

# Регуларни изрази

Израз	Опис
$?$	нула или једно појављивање
$*$	нула или више појављивања
$+$	једно или више појављивања
$\{n\}$	$n$ појављивања
$\{n, \}$	$n$ или више појављивања
$\{n, m\}$	$n$ до $m$ појављивања

Table 4: Регуларни изрази

# Претраге регуларним изразима

```

1 [a-z0-9_]{3,16}
2 #?([a-f0-9]{6}|[a-f0-9]{3})
3 ([a-z0-9_\.-]+)@([\da-z_\.-]+\.[a-z_\.-]{2,6})
4 (https?:\/\/\/?)([\da-z_\.-]+\.[a-z_\.-]{2,6})([\/\w_\.-]*)*\/?
5

```

# "Фази" претраге

- Lucene подржава "фази" претраге (тј. претраге по сличним речима)
- Сличност је дефинисана мером Levenshtein Distance (минималним бројем знакова које је потребно променити да би се једна речи трансформисала у другу реч)

# "Фази" претраге

- 1 roam~
- 2 roam~0.8
- 3

# Претраге по близини

- Lucene подржава претрагу докумената у којима се одређене речи налазе на одређеном растојању

# Претраге по близини

```
1 "jakarta apache"~10
2
```



# Претраге по интервалима

- Lucene подржава претрагу докумената чија поља имају вредности у одређеном интервалу
- Интервали се специфицирају навођењем доње и горње границе и могу да буду отворени ("{" и "}") и затворени ("[" и "]")

# Претраге по интервалима

```
1 mod_date:[20020101 TO 20030101]
2 title:{Aida TO Carmen}
3
```

# "Појачавање" термина

- Lucene подржава појачавање релевантности једног термина у односи на друге термине (релевантност термина утиче на рангирање резултата претраге)
- Што је фактор појачавања већи, термин је јелевантнији (фактор појачавања мора да буде позитиван)

# "Појачавање" термина

```
1 jakarta apache
2 jakarta^4 apache
3 "jakarta apache"^4 "Apache Lucene"
4
```

# Логички оператори

- Lucene подржава комбиновање термина коришћењем логичких оператора
- То су оператори AND, "+", OR, NOT и "-"
- Логички оператор OR се подразумева

# Логички оператори

```
1 "jakarta apache" jakarta
2 "jakarta apache" OR jakarta
3 +jakarta lucene
4 "jakarta apache" AND "Apache Lucene"
5 "jakarta apache" NOT "Apache Lucene"
6 "jakarta apache" -"Apache Lucene"
7
```

# Груписање

- Lucene подржава груписање израза коришћењем заграда

# Груписање

1 (jakarta OR apache) AND website

2



# Преглед садржаја

- 1 Увод
- 2 Текст
- 3 Претрага и индексирање
- 4 Apache Lucene Core
- 5 **Закључак**

# Закључак

- Методе репрезентације текста
- Низ знакова
- Вектор
- Фреквенција  $n$ -торки
- Кодови
- Unicode

# Закључак

- Претрага
- Прегледање
- Индексирање
- Претраживачи

# Закључак

- Apache Lucene Core
- Анализатори
- Query Parser упитни језик
- Термини
- Поља
- Упити

# Закључак

- Претраге "џокер" знацима
- Претраге регуларним изразима
- "Фази" претраге
- Претраге по близини
- Претраге по интервалима
- "Појачавање" термина
- Логички оператори
- Груписање

# Литература

- Apache Lucene Core, <https://lucene.apache.org/>

# Хвала на пажњи!